TRAVAUX PRATIQUES 4 · PANDAS ET SCIKIT-LEARN · BINÔME

Fêtes et consommation au Sénégal : dix ans d'achats à la loupe

Korité, Tabaski, Tamkharit, Magal de Touba, Maouloud, Pâques, pèlerinage de Popenguine et Noël, de 2016 à 2025 : mesurer, prévoir, comprendre

Information	Détail
Module	Python avancé · Licence 3 Intelligence Artificielle
Établissement	ISM École d'ingénieurs
Enseignant	Elias BADJI
Séance	4 / 8 · Machine Learning avec scikit-learn
Durée	1 h 30 en séance, puis travail en autonomie
Date de rendu	21 Oct 2026
Binôme	Étudiant 1 : …… Étudiant 2 : ……

1. Contexte

Au Sénégal, le calendrier des achats ne suit pas seulement les mois : il suit les fêtes. Avant la **Tabaski**, les familles achètent le mouton, les oignons et les habits neufs ; pendant le **Ramadan**, le sucre, le lait et les dattes ; à **Touba**, le **Magal** réunit chaque année plusieurs millions de pèlerins ; à **Pâques**, les familles chrétiennes préparent le ngalakh qu'elles partagent avec leurs voisins musulmans ; à **Noël**, on achète jouets et volailles.

Un réseau fictif de **10 points de vente**, de Dakar à Ziguinchor, vous confie dix ans de ventes journalières et une enquête annuelle auprès des ménages. Votre binôme doit répondre à quatre questions de la direction :

1. **Mesurer** : quels produits s'envolent avant chaque fête, de combien, et dans quelles villes ?
2. **Prévoir** : peut-on prévoir la demande de 2025 avec un an d'avance, alors que les fêtes musulmanes avancent d'environ 11 jours chaque année dans le calendrier grégorien ?
3. **Comprendre** : quels ménages s'endettent après une fête, et pourquoi ?
4. **Agir** : quelles quantités prévoir pour les fêtes de 2026 ?

> **Données fictives**
>
> Toutes les données sont **simulées** à des fins pédagogiques. Les ordres de grandeur sont plausibles, mais ils ne décrivent pas le comportement réel des Sénégalais ni d'aucune communauté religieuse. Aucune conclusion sur une communauté ne doit être tirée de ce TP.
>
> Les dates des fêtes musulmanes sont calculées avec le calendrier Umm al-Qura décalé d'un jour ; au Sénégal, elles peuvent différer d'un jour selon l'observation de la lune.

2. Compétences visées

- Auditer et nettoyer un jeu de données volumineux (plus de 500 000 lignes) avec Pandas.
- Construire des variables calendaires liées à des événements mobiles (`merge_asof`, distances en jours).
- Mesurer un effet par comparaison à une période de référence, et repérer les chevauchements d'événements.
- Prévoir une série de comptages avec scikit-learn, avec un découpage temporel strict et des références naïves.
- Construire une classification probabiliste, l'interpréter et poser la question de l'équité.
- Segmenter des ménages par K-means, puis traduire des prévisions en recommandations chiffrées.

3. Données

L'archive `tp4_achats_evenements_data.zip` contient cinq fichiers CSV séparés par des virgules, encodés en UTF-8.

Fichier	Lignes	Contenu
`ventes_journalieres.csv`	530 790	Ventes par jour, point de vente et catégorie, 2016-2025 : quantité, prix unitaire, chiffre d'affaires, promotion, part des paiements mobiles
`enquete_menages.csv`	49 406	Une ligne par ménage, par fête et par année : profil du ménage, dépenses par poste, financement, endettement après la fête
`calendrier_evenements.csv`	103	Dates de chaque fête d'octobre 2015 à décembre 2026, y compris le Ramadan (début et fin)
`magasins.csv`	10	Ville, région, type de point de vente, milieu, date d'ouverture
`categories.csv`	15	Unité de vente, famille de produits, prix de référence 2016

Les événements étudiés

Événement	Ce que l'on célèbre	Date
Ramadan et Korité	Mois de jeûne, puis fête de sa fin (Aïd el-Fitr)	1er chawwal, mobile
Tabaski	Aïd el-Kébir : sacrifice d'un mouton en famille	10 dhou al-hijja, mobile
Tamkharit	Achoura, dixième jour de l'année musulmane : repas de couscous	10 mouharram, mobile
Magal de Touba	Départ en exil de Cheikh Ahmadou Bamba ; grand pèlerinage à Touba	18 safar, mobile
Maouloud (Gamou)	Naissance du Prophète ; grands rassemblements à Tivaouane et à Médina Baye (Kaolack)	12 rabi al-awwal, mobile
Pâques	Résurrection du Christ ; partage du ngalakh	Variable, mars-avril
Pèlerinage de Popenguine	Pèlerinage marial national, près de Mbour	Lundi de Pentecôte
Noël	Naissance du Christ	25 décembre

Colonnes principales

Colonne	Signification
`date`, `magasin_id`, `categorie`	Clé d'une ligne de vente (un jour, un point de vente, une catégorie)

Colonne	Signification
`quantite`	Unités vendues dans la journée (kg, litres, têtes, articles…)
`prix_unitaire_fcfa`, `chiffre_affaires_fcfa`	Prix moyen du jour et chiffre d'affaires
`promo`	1 si la catégorie était en promotion ce jour-là (décidée à l'avance par le réseau)
`part_paiement_mobile`	Part du chiffre d'affaires payée par mobile money
`evenement`, `depense_totale_fcfa`	Fête concernée et dépense totale du ménage pour cette fête
`dep_alimentation_fcfa` … `dep_cadeaux_dons_fcfa`	Répartition de la dépense en cinq postes
`financement_principal`	Épargne, tontine, crédit, transfert de la diaspora ou aide familiale
`endette_apres_fete`	1 si le ménage déclare une dette non remboursée un mois après la fête (cible de la partie 5)

Comme toutes les données réelles, les fichiers contiennent des **défauts**. Les trouver fait partie du travail.

4. Règles du jeu

1. **Découpage temporel strict.** Entraînement : 2016 à 2023. Validation : 2024. Test : 2025, utilisé **une seule fois** pour l'évaluation finale.
2. **Prévision à un an.** Pour prévoir 2025, vous ne pouvez utiliser que ce qui est connu un an à l'avance : le calendrier, le point de vente, la catégorie et les promotions planifiées. Les ventes récentes, comme celles de la veille, sont interdites.
3. **Pipeline obligatoire** dès qu'une étape apprend quelque chose des données : imputation, encodage, mise à l'échelle.
4. **Reproductibilité.** `random_state` fixé ; le notebook s'exécute sans erreur avec « Redémarrer et tout exécuter ».
5. **Variables sensibles.** La religion et la confrérie ne servent qu'à l'analyse d'équité de la partie 5, jamais à un modèle livré.

5. Travail demandé

Partie 1 · Audit et nettoyage (3 points)

Chargez `ventes_journalieres.csv` avec `parse_dates`. Produisez un **rapport d'audit** chiffré : doublons, catégories mal saisies, valeurs manquantes, quantités négatives, valeurs aberrantes, jours manquants par point de vente. Pour chaque défaut, justifiez votre traitement en une phrase. Attention : un pic de ventes avant une fête n'est pas une valeur aberrante.

Partie 2 · Variables d'événement (3 points)

Écrivez une fonction `variables_calendrier(dates)` qui renvoie, pour chaque date et chaque fête, le nombre de **jours avant** la prochaine occurrence (`av_tabaski`…) et le nombre de **jours depuis** la précédente (`ap_tabaski`…), plafonnés, ainsi qu'un indicateur `ramadan`. Utilisez `pd.merge_asof`, sans boucle sur les lignes de ventes.

Montrez ensuite, à partir du calendrier, de combien de jours la Tabaski se décale d'une année sur l'autre, et expliquez pourquoi une variable « mois » ne suffit pas à capter l'effet des fêtes musulmanes.

Partie 3 · Mesurer l'effet des fêtes (4 points)

Pour chaque fête, définissez une **fenêtre d'achat** (par exemple J-7 à J-1 pour la Tabaski) et une **période de référence** (J-60 à J-31). L'**uplift** est le rapport entre la vente moyenne par jour dans la fenêtre et celle de la référence.

- Donnez les trois catégories les plus touchées par chaque fête, au niveau national.
- Comparez le Magal et le Maouloud **par point de vente** : que se passe-t-il à Touba, à Tivaouane, à Kaolack et à Dakar ?
- Représentez l'ensemble par une carte de chaleur événement × catégorie.
- Repérez au moins **un chevauchement d'événements** qui fausse un uplift, et expliquez-le.
- Sur dix ans : chiffre d'affaires nominal et réel (déflaté par un indice de prix que vous construirez), prix du mouton avant la Tabaski, part du paiement mobile.

Partie 4 · Prévoir la demande un an à l'avance (5 points)

Cible : la quantité vendue par jour, point de vente et catégorie. Métrique : le **WAPE**, somme des erreurs absolues divisée par la somme des ventes réelles (annexe). Calculez-le sur toute l'année et sur les seules **fenêtres d'événement** (14 jours avant une fête).

1. Deux références naïves : la vente du **même jour de la semaine un an plus tôt** (364 jours avant) et la **moyenne 2024** par point de vente, catégorie et jour de la semaine.
2. Une régression `Ridge` dans un `Pipeline` avec `ColumnTransformer`, cible transformée en `log1p`.
3. Un `HistGradientBoostingRegressor` : choisissez la fonction de perte et les variables sur la **validation 2024**, en justifiant.
4. Réentraînez sur 2016-2024, évaluez une seule fois sur 2025, puis détaillez le WAPE par fête.
5. Les modèles sous-estiment-ils les pics ? Comparez les totaux prévus et réels pour trois pics de 2025, et concluez sur le choix de la perte.

Partie 5 · Qui s'endette après la fête ? (3 points)

Avec `enquete_menages.csv` : décrivez la dépense médiane et le taux d'endettement par fête et par mode de financement. Entraînez une régression logistique et un `HistGradientBoostingClassifier` (entraînement 2016-2023, test 2024-2025) et comparez-les avec le ROC AUC, le PR AUC et le score de Brier. Identifiez les variables qui comptent par importance de permutation.

> **Question d'équité obligatoire**
> Réentraînez le meilleur modèle **sans** la religion ni la confrérie. La performance change-t-elle ? Qu'en concluez-vous pour un organisme de microfinance qui voudrait utiliser ce modèle ? Argumentez en 5 à 10 lignes.

Partie 6 · Profils de dépense (1 point)

Pour l'année 2025, agrégez les dépenses de chaque ménage sur toutes ses fêtes, calculez la part de chaque poste et un indicateur d'effort (log de la dépense annuelle des fêtes rapportée au revenu mensuel). Segmentez par K-means, choisissez k avec la silhouette **et** l'interprétabilité, puis décrivez chaque groupe.

Partie 7 · Plan 2026 et note de synthèse (1 point)

Construisez la grille 2026 (365 jours × 10 points de vente × 15 catégories), prévoyez-la avec votre meilleur modèle et comparez au réel 2025 pour la semaine précédant la Tabaski, le Magal à Touba et Noël. Rédigez une **note d'une page** pour la direction : quantités recommandées, hypothèses retenues, limites.

Bonus (jusqu'à +2 points)

- Intervalles de prévision par régression quantile (`loss="quantile"`) pour dimensionner un stock de sécurité.
- Mesurer l'effet propre des promotions, sachant qu'elles sont plus fréquentes avant les fêtes : expliquer le biais de confusion.
- Tableau de bord Streamlit (séance 3) : choix d'une fête, d'une ville et d'une catégorie, courbe alignée sur J0.

6. Livrables et barème

- `TP4_Nom1_Nom2.ipynb` exécuté, avec une conclusion en Markdown à la fin de chaque partie.
- La note de synthèse de la partie 7, en PDF, une page.
- Usage d'un assistant IA autorisé s'il est déclaré ; chaque membre doit pouvoir expliquer chaque ligne à l'oral.

Partie	Contenu	Points
1	Audit et nettoyage justifiés	3
2	Variables d'événement avec merge_asof	3
3	Uplifts, chevauchements, évolution sur dix ans	4
4	Prévision : références, Ridge, HGB, analyse des pics	5

Partie	Contenu	Points
5	Endettement : modèles, interprétation, équité	3
6	Segmentation des ménages	1
7	Plan 2026 et note de synthèse	1
Total		**20**
Bonus	Quantiles, promotions, tableau de bord	+2

Annexe · Formules

Uplift d'une fête pour une catégorie = vente moyenne par jour dans la fenêtre ÷ vente moyenne par jour dans la référence (J-60 à J-31). Un uplift de 3 signifie des ventes trois fois plus élevées que d'habitude.

WAPE = Σ |réel − prévu| ÷ Σ réel. Contrairement au MAPE, il ne diverge pas quand une vente vaut zéro, et il pondère naturellement les catégories par leur volume.

Indice des prix de l'année a = Σ poids2016(c) × prix médian(a, c) ÷ prix médian(2016, c), où le poids d'une catégorie est sa part du chiffre d'affaires de 2016. Chiffre d'affaires réel = nominal ÷ indice.

Perte de Poisson : adaptée aux comptages positifs ; le modèle prévoit l'espérance du nombre d'unités vendues, si bien que la somme des prévisions approche la somme des ventes.

Silhouette d'un point = (b − a) ÷ max(a, b), avec a la distance moyenne aux points de son groupe et b la distance moyenne au groupe voisin le plus proche. Elle varie de −1 à 1 ; plus elle est élevée, mieux les groupes sont séparés.